



Makine Öğrenmesi – 6 **Unsupervised Learning** 



#### **Overall Table of Contents**




#### **General Content**

UNsupervised Learning—

#### K-Means - PCA


- UNsupervised Algorithm practices Python application
- Projects Solutions




## RU RU

#### **Run Navigation...**

# Where are we? Machine Learning Course Machine Learning Course DATA ACQUISITION DATA CLEANING MODEL TRAINING & BUILDING MODEL DEPLOYMENT









#### **Overall Table of Contents**


- Unsupervised Learning Algorithm (Denetimsiz Öğrenme)
- Unsupervised Algorithm practices Python application
- Projects Solutions


## 01

#### **Unsupervised Learning**










#### Exploratory Data Analysis and Visualization


#### Machine Learning


- Train | Test Split
  - X\_train, X\_test, y\_train, y\_test = train\_test\_split()
- Scalling (if needed)
  - scaler = scaler name()
  - scaler.fit\_transform(X\_train)
  - scaler.transform(X\_test)
- Modelling
  - model = model\_name().fit(X\_train, y\_train)
  - y\_pred = model.predict(X\_test)
  - y\_pred\_proba = model.predict\_proba(X\_test)
- Model Performance
  - Regression => r2\_score, MAE, MSE, RMSE
  - Classification => accuracy, recall, precision, f1\_score (confusion\_matrix, classification\_report)
  - Cross Validate => cross\_val\_score, cross\_validate
- Tunning (if needed)
  - grid\_param = {}
  - GridsearchCV(grid\_param)
- Final Model
  - model = model\_name().fit(X, y)
- Model Deployment




#### CLUSTERING' E GİRİŞ (Kümeleme)

- **Clustering tipleri** 
  - 1. Partitional clustering (K-means)






(7) (8) 41 (5) (10) (7) (4) (8) (9) (15) (5) (7) (4) (22)(15)(23) Number of points in node (or index of point if no parenthesis).





#### K-MEANS (K-Ortalamalar) CLUSTERING

**&** Hyperparameters







#### **Unsupervised Learning**

#### K-MEANS (K-Ortalamalar) CLUSTERING

Cluster Modelleri için PERFORMANS DEGERLENDİRME METRIKLERI

- Cluster'lar ne kadar anlamlı
- Optimum sayıda cluster var mı
- Cluster ları doğrulamaya ihtiyaç var mı







#### K-MEANS (K-Ortalamalar) CLUSTERING

#### **©** Performans Ölçütleri

- ☑ Dışsal Kümeleme Doğrulaması

- Mutual Information Score (MIS)
- **∀** V-measure:
- Eksiksizlik (Completeness)



#### **Unsupervised Learning**

#### K-MEANS (K-Ortalamalar) CLUSTERING

❷ Performans Ölçütleri


Silhouette Metodu

 $Silhouette\ Katsayısı = (b-a)/\max(a,b)$ 




a= küme içi ortalama mesafe (bir kümenin içindeki tüm veri noktalarının birbirleri arasındaki ortalama mesafe)

b= kümeler arası ortalama mesafe (tüm kümelerin arasındaki mesafelerin ortalaması











#### K-MEANS (K-Ortalamalar) CLUSTERING

**e** Performans Ölçütleri

**€** Elbow Metodu









#### **Unsupervised Learning**

#### 

Silhouette ve Elbow Metotlarına Göre Optimum Küme Seçimi



Silhouette Metodunda, optimum küme sayısı (K) farklı küme sayıları için hesaplanan skorlardan en büyüğüne karşılık gelen değerdir. Bu örnekte K=3 optimum olarak görülmektedir.




Dirsek Metodunda, optimum küme sayısı (K) grafiğin dirsek şeklinde karıldığı/büküldüğü noktaya karşılık gelen değerdir. Bu örnekte K=3 optimum olarak görülmektedir.

Son tahlilde, bir değerlendirme ölçütü olmakla birlikte denetimli makine öğrenmesinde kullanılan değerlendirme ölçütleri kadar kesinlik atfetmeden bir miktar ihtiyatla yaklaşmak gerekir.



#### PRINCIPAL COMPONENT ANALYSIS - PCA

(Temel Bileşenler Analizi)





#### **Unsupervised Learning**

#### PRINCIPAL COMPONENT ANALYSIS -PCA


- *⊙* Feature Selection
- ② Dimensionality Reduction



Principal Components Analysis (PCA)


Set A

PCA, değişkenlerdeki bilgilerin çoğunu temsil eden daha küçük bir bileşen kümesine indirmeye çalışan bir karmaşıklık azaltma tekniğidir.





### PRINCIPAL COMPONENT ANALYSIS –PCA




Temel Bileşenler

5

2



#### PRINCIPAL COMPONENT ANALYSIS -PCA



```
109 # Açıklanan Varyans Oranları:
110 # Hangi temel bileşen incelene olayı ne kadar açıklıyor?
111 explained_variance=pca.explained_inertia_
112 print(explained_variance)
113
```

[0.4984116865967306, 0.2355096143382977, 0.10512215087762719, 0.09197939016712874, 0.0434179988625223, 0.025559159157693058]



#### **Unsupervised Learning - PCA**

```
130 # Grafik: Sütun Korelasyonu

131 pca.column_correlations(df2[features])

132

133 scatter = pd.DataFrame(pca.column_correlations(df2[features])).reset_index()

134 plt.figure(figsize=(10,6))

135 ax = sns.catterplot(xea, y=1, data=scatter)

136 ax.set(ylim=(-1, 1), xlim=(-1,8))

137 def label_point(x, y, v=1, ax):

138 a = pd.concat('x': x, 'y': y, 'val': val}, axis=1)

139 for i, point in a.iterrows():

140 ax.text(point['x']+.82.point['y'], str(point['val']))

141 label_point(scatter[0], scatter[1], scatter['index'], plt.gca())

142 plt.awline(-0.5, lss'--')

143 plt.awline(-0, ss'--')


144 plt.title('Deijskenlerin Temel Bileşen 1 ve 2 icindeki pozisyonları',

145 fontsize=18)

146 plt.xlabel('Temel Bileşen 1 (50%)', fontsize=18)

147 plt.ylabel('Temel Bileşen 2 (24%)', fontsize=18)


148 plt.show()
```





#### **Unsupervised Learning - PCA**

```
194 # Öznitliklerin herbir temel bileşen içinde açıklanan varyansa yaptığı
195 # katkıyı (Eigenvectors) tablolaştırarak inceleyelim
196 t=pca.column_correlations(df2[features]).transpose()
197 features_names=pd.Series(t.columns)
198 s= pd.Series(["PC1", "PC2", "PC3", "PC4", "PC5", "PC6"])
199 t=t.set_index(s)
201 # Grafiğe hazır hale getirmek için t dataframeini numpay array fromatına
202 # dönüştürelim ve 2 basamaklı ondalık değerine yuvarlayalım:
203 t=t.to_numpy()
284 t=t.round(2)
206 # Graf: Özniteliklerin Temel Bileşenlerdeki Önemi:
207 fig, ax = plt.subplots(figsize=(12, 6))
208 plt.imshow(t, interpolation = 'none', cmap = 'plasma')
209 feature_names = features_names
210 # Temel bilesenler ve özniteliklerin grafikteki konumları...
211 ax.set_xticks(np.arange(-.5, len(feature_names)));
212 ax.set_yticks(np.arange(0.5, 6));
213 ax.set_wticklabels(feature_names, rotation=90, ha='left', fontsize=16);
214 ax.set_yticklabels(s, va='bottom', fontsize=16);
215 # Kutucuklarda egeanvalues değerlerini göstermek için...
216 for i in range(len(s)):
          for j in range(len(feature_names)):
    text = ax.text(j, i, t[i, j],
218
                                  ha="center", va="center", color="w")
221 plt.title('Özniteliklerin Temel Bileşenler İçindeki Önemi', fontsize=20)
222 plt.colorbar(orientation='vertical', ticks=[t.min(), 0,t.max()]);
```








#### **Unsupervised Learning**

## DIMENSION REDUCTION (Boyut Azaltma)

**Giriş** 







Burada boy (X1) ve kio (X2) bir ilk okul sınıfındaki öğrencilerin cinsiyetini tanımlayan iki öznitelik olsun. Her ki değişken de bir ölçüde tek başlarına öğrencilerin cinsiyetlerini tanımladığını varsayalım (ilkokul oğrencilerin her kibini de kullanırsak, benzer bilgileri aktarırlar. Bu nedenle, yalınıza bir değişken kullarına ke kullanırsak, benzer bilgileri aktarırlar. Bu nedenle, yalınıza bir değişken kullanmak mantıklı olacaktır. Verileri 20'den (X1 ve X2) 10 (Y1) a vaşağıda gösterliği gibi dönüştürebiliriz. Benzer şekilde, verilerin d saydaki boyutunu ayrı bilgiyi jermek kaydıyda bir alt kümesine indirgeyebiliriz. Buna boyut azaltına denir.

y1 vektörü



#### DIMENSION REDUCTION (Boyut Azaltma)

- *❷* Feature Selection
- **@** Feature Extraction





#### **Unsupervised Learning**

#### **DIMENSION REDUCTION (Boyut Azaltma)**

**PCA ile Dimension Reduction** 







- 2 human
- children
- long hair put their hands
- together - height etc.

The area marked in Set A contains approximately
70% of the information contained in the pink, blue and yellow circles.






2D (shadow of the children) represent most of the information of real






#### **DIMENSION REDUCTION (Boyut Azaltma)**

**PCA ile Dimension Reduction** 










#### **Unsupervised Learning**

#### **DIMENSION REDUCTION (Boyut Azaltma)**

**PCA ile Dimension Reduction** 

- 26 # KNN Simiflandiricisi: 27 n\_neighbors=3 # en yakın komşu sayısını 3 seçelim. 28 KNN = neighbors.KNeighborsClassifier(n\_neighbors, weights='distance') 29 KNN.fit(X\_train, y\_train) 31 # Eğitim Seti performansı 32 pred\_invest\_grade\_train =KNN.predict(X\_train) 33 print('Doğruluk (Accuracy):%0.2f'% accuracy\_score(y\_train, pred\_invest\_grade\_train)) 34 # Test Seti Performansı 35 pred\_invest\_grade\_test =KNN.predict(X\_test) 36 print('Doğruluk (Accuracy):%0.2f'% accuracy\_score(y\_test, pred\_invest\_grade\_test)) Doğruluk (Accuracy):1.00
  - Doğruluk (Accuracy):0.92
- 49 # top. varyansın %80'ini açıklayan temel bileşenlere
- 50 # göre modeli tekrar oluşturalım:
- 51 pca = PCA(n\_components = 0.80)
- 52  $X_pca = pca.fit_transform(X_train) # eğitim setini dönüştürüp boyutunu azaltır.$
- 53 print(pca.n\_components\_) # top. varyansın %80'i kaç temel bileşen ile açıklanıyor?

54




0.4

0.3



#### **DIMENSION REDUCTION (Boyut Azaltma)**

- **©** PCA ile Dimension Reduction
  - Avantajları
  - Dezavantajları



```
104 # Eğitim Seti Performansı
105 pred_invest_grade_pca_train =clf.predict(PC_Df)
106 print('Doğruluk (Accuracy):%0.2f'%
107 accuracy_score(y_train,pred_invest_grade_pca_train))
108 # Test Seti Performansı
109 pred_invest_grade_pca_train =clf.predict(PC_Df)
110 print('Doğruluk (Accuracy):%0.2f'%
111 accuracy_score(y_train,pred_invest_grade_pca_train))
112
```

Doğruluk (Accuracy):1.00 Doğruluk (Accuracy):1.00



Bu dersi anladım...











## Do you have any questions?

Send it to us! We hope you learned something new.